SACC 2014中国系统架构师大会
SYSTEM ARCHITECT CONFERENCE CHINA 2014
发现架构之美

新浪微博redis优化历程

陈波 @fishermen

大纲

- 业务场景
- Redis存储架构演进
- 一些经验
- Q&A

业务场景-业务

- Redis在新浪微博的应用

业务场景-数据

- 一些数据

6 IDC	500+servers
3700+ instances	千亿条记录
24T+内存	7千亿cmds/day
1.2万亿read/day	2千亿write/day

Redis存储前时代

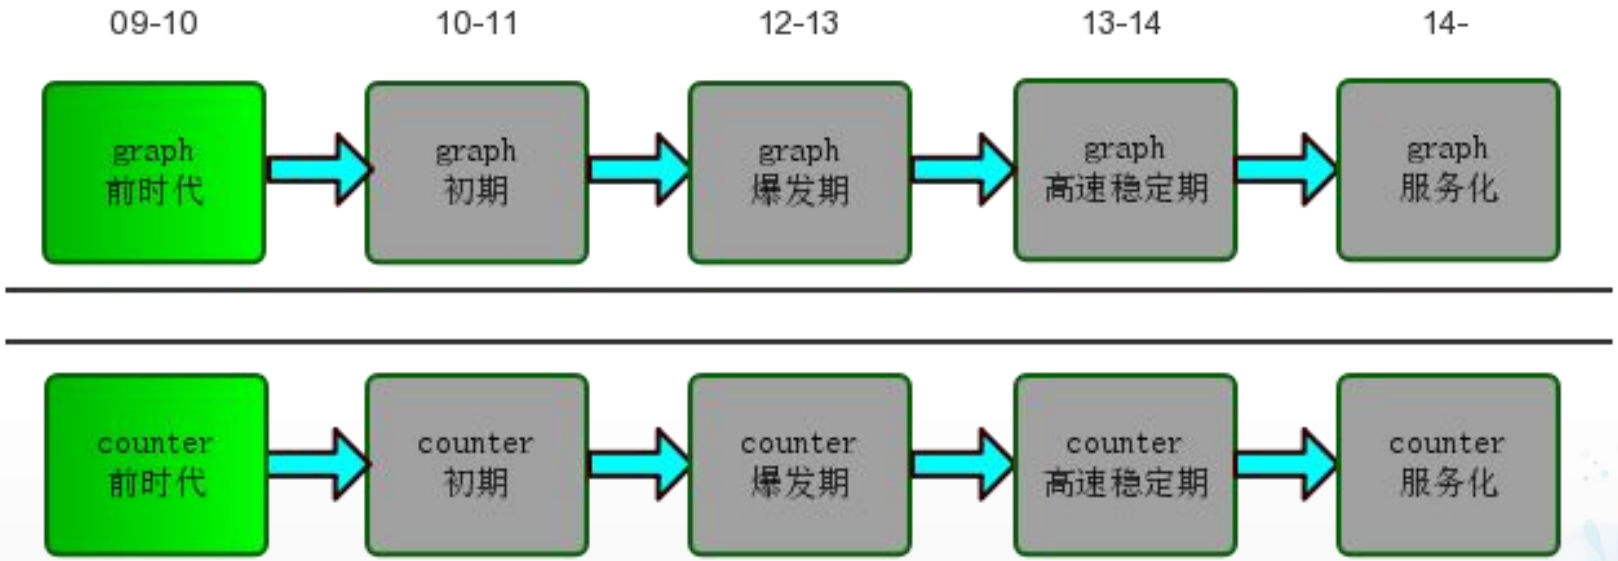
09-10
10-11
12-13
13-14
14-
graph 前时代
graph 初期
graph 爆发期
graph 高速稳定期
graph 服务化
counter 前时代
counter 初期
counter 爆发期
counter 高速稳定期
counter 服务化

Redis前时代

- 热数据mc
- 全量落地mysql
- 数据量不大：Graph mc 10G，计数器 mc 2G
- 开发速度

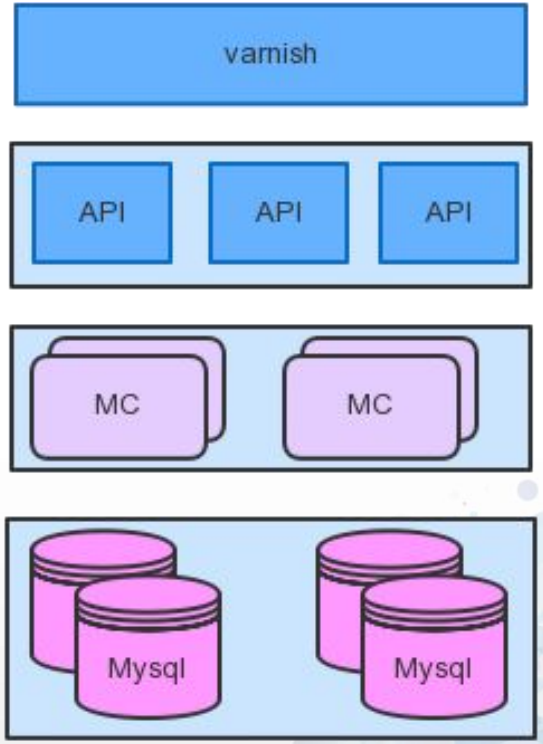

问题出现

- 2010年，Graph mc 30G+，峰值 10wTPS

- Mysql成为瓶颈
  - 线程阻塞，访问卡顿
  - List类型业务不适合mysql

- 新的关系计算需求实现困难
  - 大量关系计算：从MC取全量+本地计算->超时

解决方案

- 初期方案
  - 增大mc容量到40G，Graph db 增至一主六从
  - 监控并及时清理僵死线程
  - 关系计算性能问题暂时无解

- 最终方案
  - 引入Redis做storage (graph/counter)
  - 关系计算 在redis实现 O(1)
  - 促进更多复杂需求
  - Graph db恢复一主三从

小结

- 项目初期
  - 30G- 日PV5kw-
  - 技术选型 熟悉度
  - 拼的是开发速度
- 产品需求与新技术相互促进

Redis存储初期

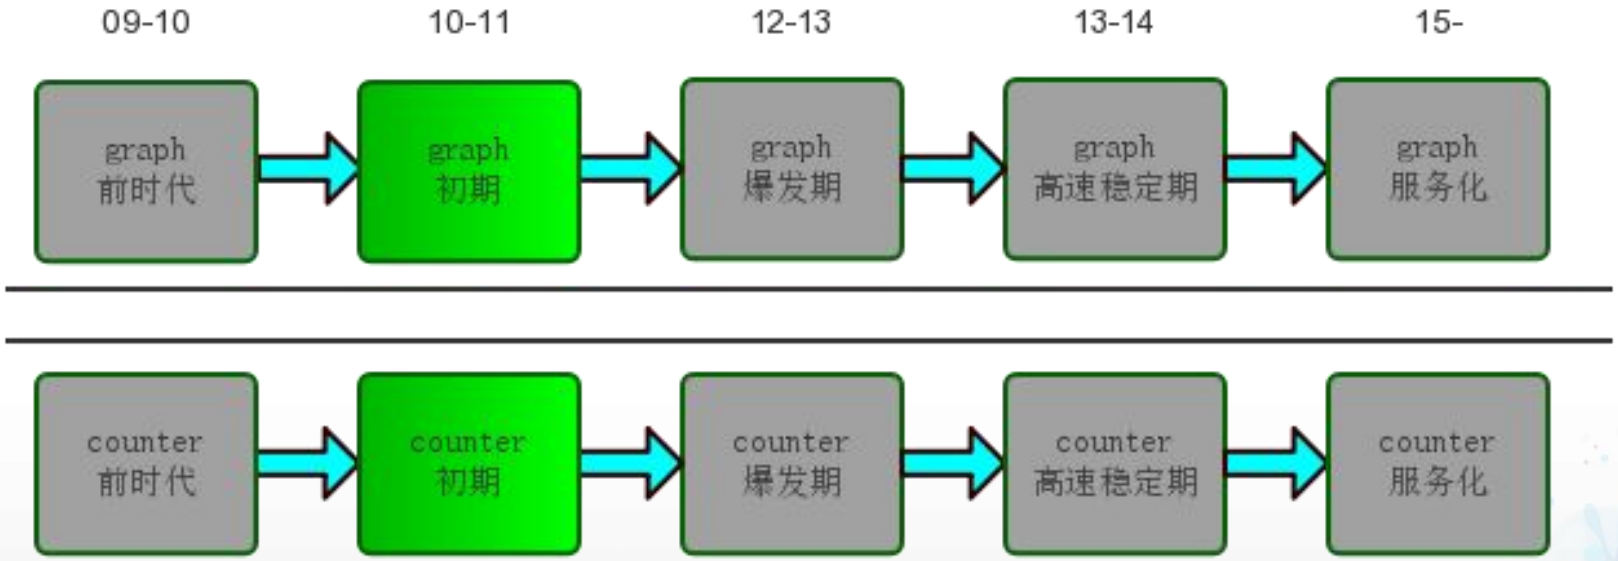
09-10
10-11
12-13
13-14
15-
graph 前时代
graph 初期
graph 爆发期
graph 高速稳定期
graph 服务化
counter 前时代
counter 初期
counter 爆发期
counter 高速稳定期
counter 服务化

Redis初期

- Redis 2.0
- Graph存hash，40G 10w TPS，4 Server
- Counter:20G 2w TPS，2 Server

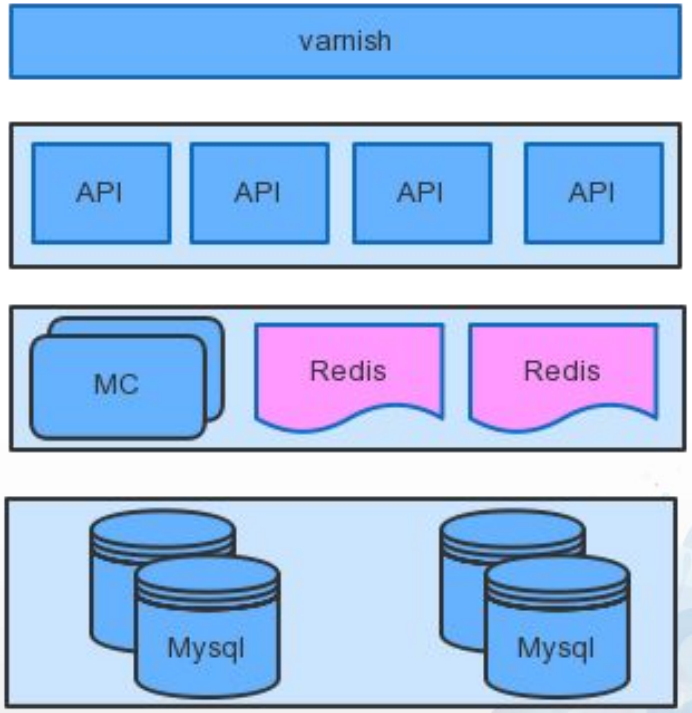

问题出现

- 2011年，初期使用经验不足
  - 数据分片过少，扩容困难
  - 部分数据类型使用不当，内存超预期
  - 多业务混放，拆分不便

- 可用性不够
  - 小业务初期没有slave，server故障→服务异常
  - 大业务挂载3-4个slave，高峰期write超时，请求失败

- 重启耗时，10-20分钟服务异常

解决方案

- 容量规划
  - 提前预估容量，上线前预拆足够的数据分片
  - 选择合适的数据类型，慎用zset
  - 业务独立存储，拒绝混放

1	Redis 容量评估表	
2	需求	
3	业务名称	
4	用途	
5	数据类型（List, String, Hash）	
6	单位(user)	
7	当前单位容量	
8	预估最大单位容量	
9	当前数量	
10	预估最大数量	
11	当前峰值(rps 读)	
12	当前峰值(rps 写)	
	预估最大峰值(rps 读)	

解决方案

- 提高可用性
  - 所有Redis全部增加Slave
  - Master挂载slave不超过2个，采用M-S-S方式挂载
  - 多IDC 单Master，复制同步

- 凌晨低峰升级，访问 IP→域名
  - 不完美，但基本可work

问题升级

- 2011年底，Graph 100G+ 灵异事件
  - 凌晨3点低峰期，redis无征兆崩溃
  - 批量升级、扩容拆分，引发其他业务异常报警

- 多个slave严重负载不均，请求数最大差1-2个数量级，峰值 响应从 不足1ms->3ms

- 在线版本增多
  - 最多6个版本
  - BUG重复修复，运维困难

问题分析

- 崩溃：读写会用pageCache，导致redis进swap而崩溃
- 其他服务报警：复制 全量推送导致网络阻塞
- 负载不均：client通过域名访问，域名解析返回随机ip，结果连接不均衡，最终导致负载不均衡

问题解决

- 紧急方案
  - 超过物理内存3/5→迁移端口
  - 错峰升级/扩容 对网络仍然有一定冲击
  - 开发ClientBalancer组件，保持域名下IP连接均衡，负载均衡

- 进一步优化方案:
  - 及时清理pagecache，减少对正常业务影响
  - Aof去掉rewrite，改用rotate
  - 类似mysql，独立IO线程对rdb、aof转发复制（社区版psync, repl-backlog-size, repl-backlog-ttl）
  - 支持热升级，避免重启，提高可运维性
  - Others…

小结

- 小规模 50G　1-2个集群
  - 人肉运维

- 中规模 100G+，3+集群
  - 可运维性->重要
  - 开源组件->熟悉架构实现

Redis存储爆发期

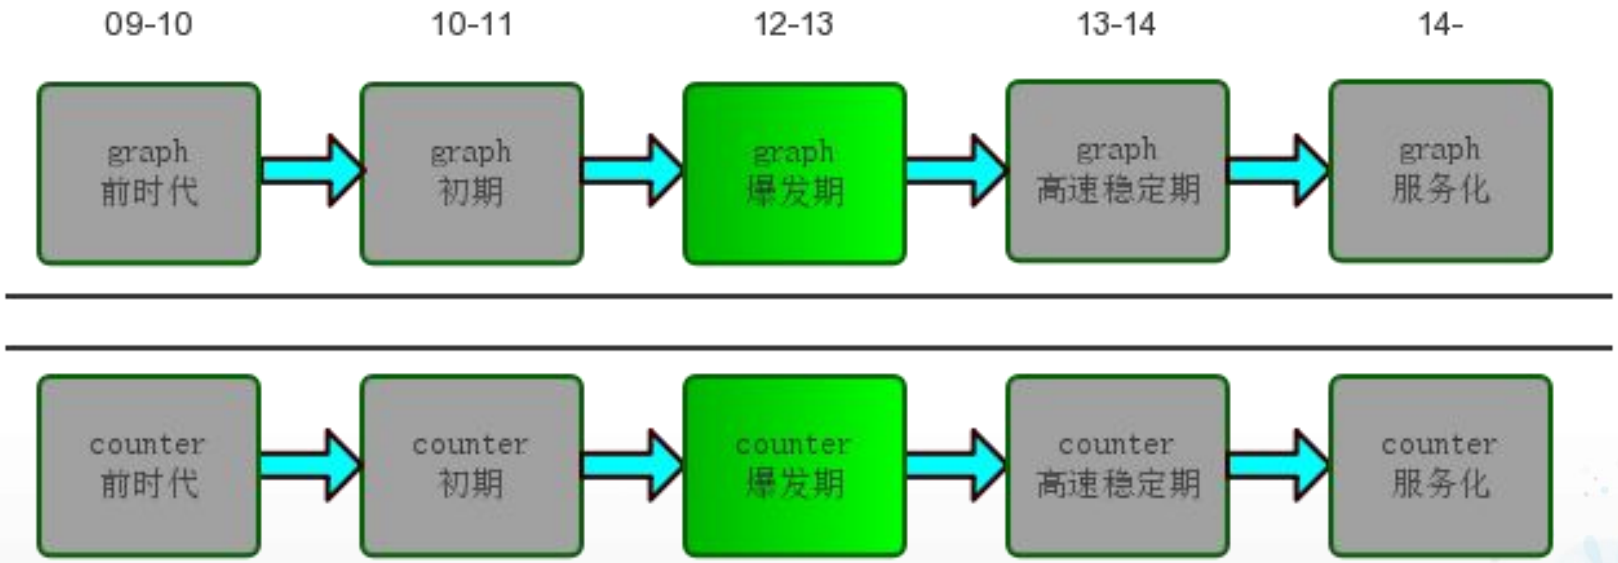
09-10
10-11
12-13
13-14
14-
graph 前时代
graph 初期
graph 爆发期
graph 高速稳定期
graph 服务化
counter 前时代
counter 初期
counter 爆发期
counter 高速稳定期
counter 服务化

Redis存储爆发期

- 完全增量复制
- 在线热升级
- SLAVE均衡访问
- 大量子业务切入
- 单业务数百G稳定

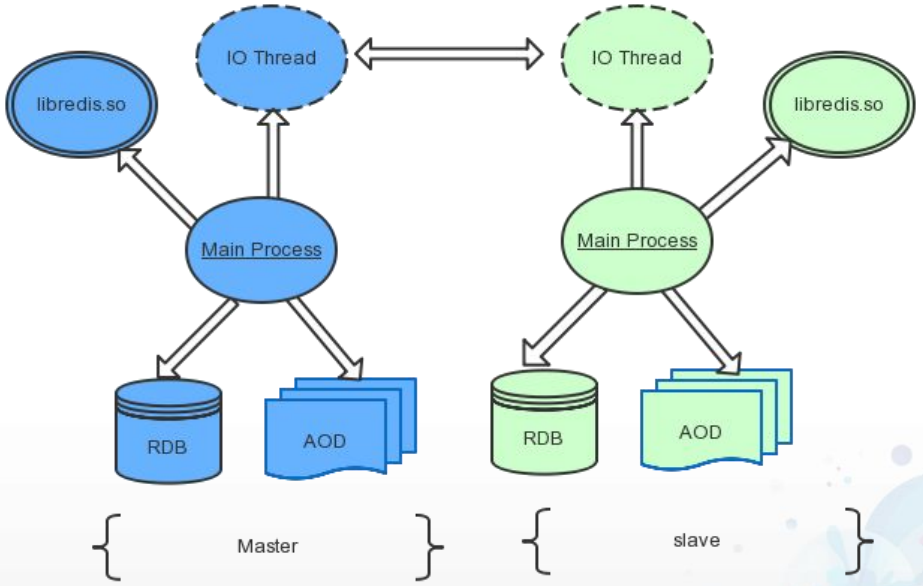

问题出现

- 2013年，Graph海量规模
  - 数据T级，MS 十T级
  - 数百台server，而且还在快速增加
  - Graph用Hash结构，存储效率不高

问题出现

- Counter 业务增加，增长迅猛
  - 日增：计数亿条 内存5G+
  - 总数据百G级， MS T级
  - Feed请求 计数近百倍读放大，高峰超时报警
  - 存储效率低 <30%

问题出现

- 占用机器增加迅猛，成本合理性需要考虑
- 部分机房机架饱和

解决方案

- Graph
  - 定位：storage→cache
  - 定制：hash→Longset
- Counter
  - 定制cdb，通过table分段存储计数
  - 一个KV存多个计数

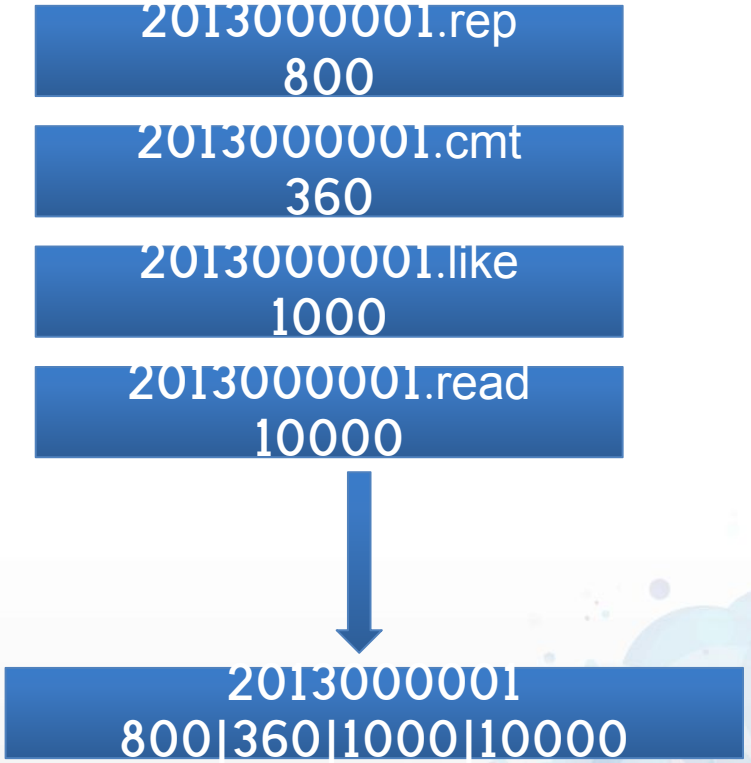

解决方案

- Counter存储结构
  - cdb=schema+tables
  - 计数double-hash寻址，消除冗余robj存储结构
  - 冲突过多aux_dict
  - 数值过大extend_dict

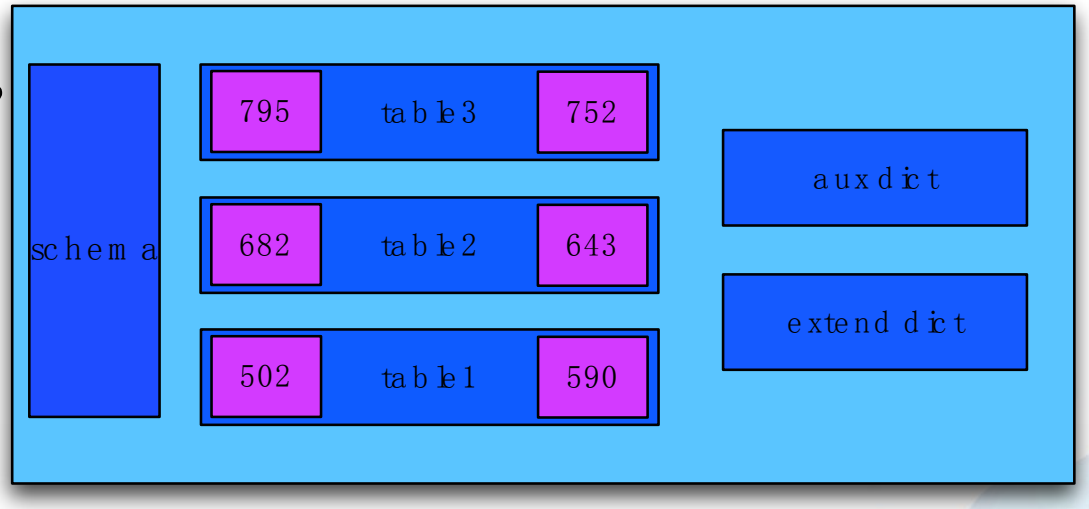

- 多管齐下，节省数百台机器

- 下线低配server，寻找廉价新机房

小结

- 量变->质变，极端业务定制
- 大规模集群 T级 3+idc 成本
  - 单个请求成本
  - 总拥有成本

Redis存储高速稳定期

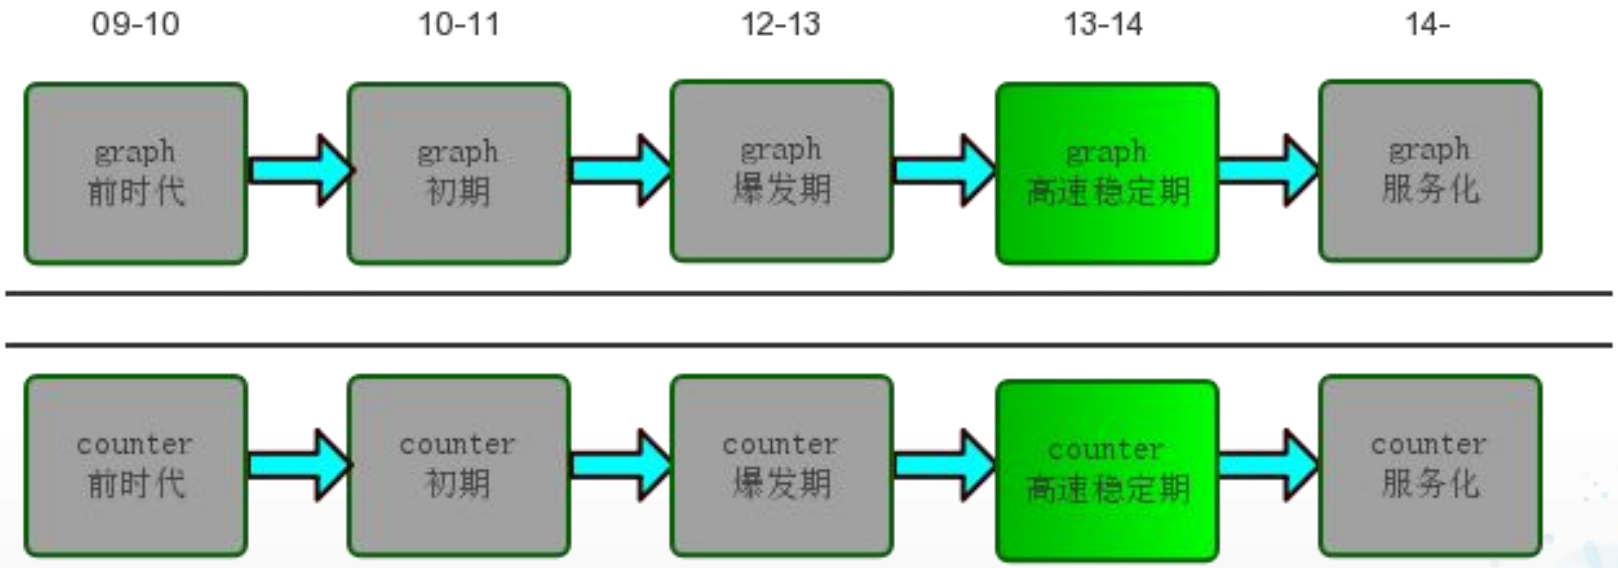

Redis存储高速稳定期

- Graph 定位cache
  定制longset
  - 内存降为 1/10
  - 性能接近

- Counter 定制cdb
  - 内存降为 1/5 -
  - 性能增3-5倍

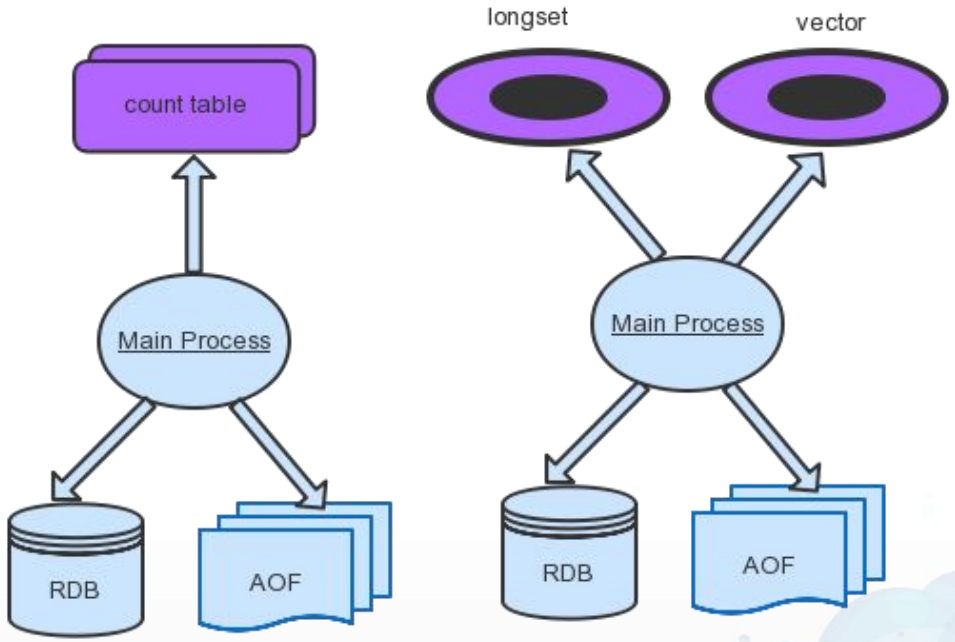

Redis存储高速稳定期

- 继续定制
  - Counter 落地SSD，容量提升20倍，8个月→10年
  - Vector
  - Others…

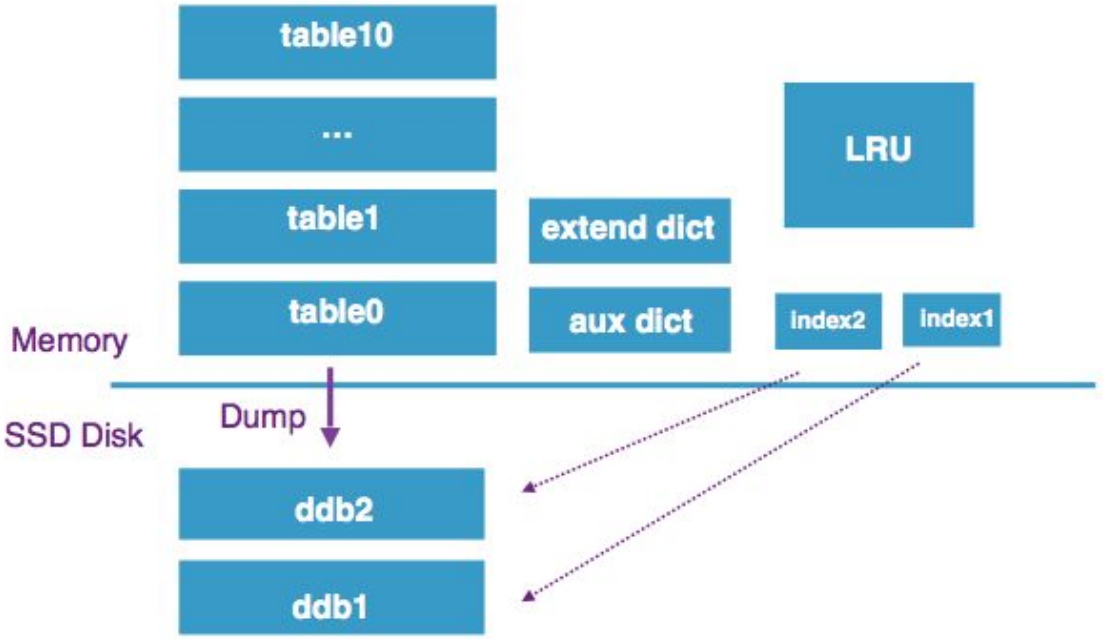

问题出现

- 2014，SLA 目标6个9
  - 数千关联Server 6+IDC 跨地域分布
  - 海量数据 24T+
  - 峰值 5000w+ TPS，响应毫秒级
  - 硬件/网络故障时有发生，如何实现？

问题解决

- 资源服务化 →
  - Configserver用于服务的发布与订阅
  - CacheService 用于集群管理
    - ✦数据路由
    - ✦负载均衡
    - ✦数据在线迁移
    - ✦服务治理（生命周期 故障转移etc.）
  - 运维标准化、自动化 （扩/缩容etc.）

服务化

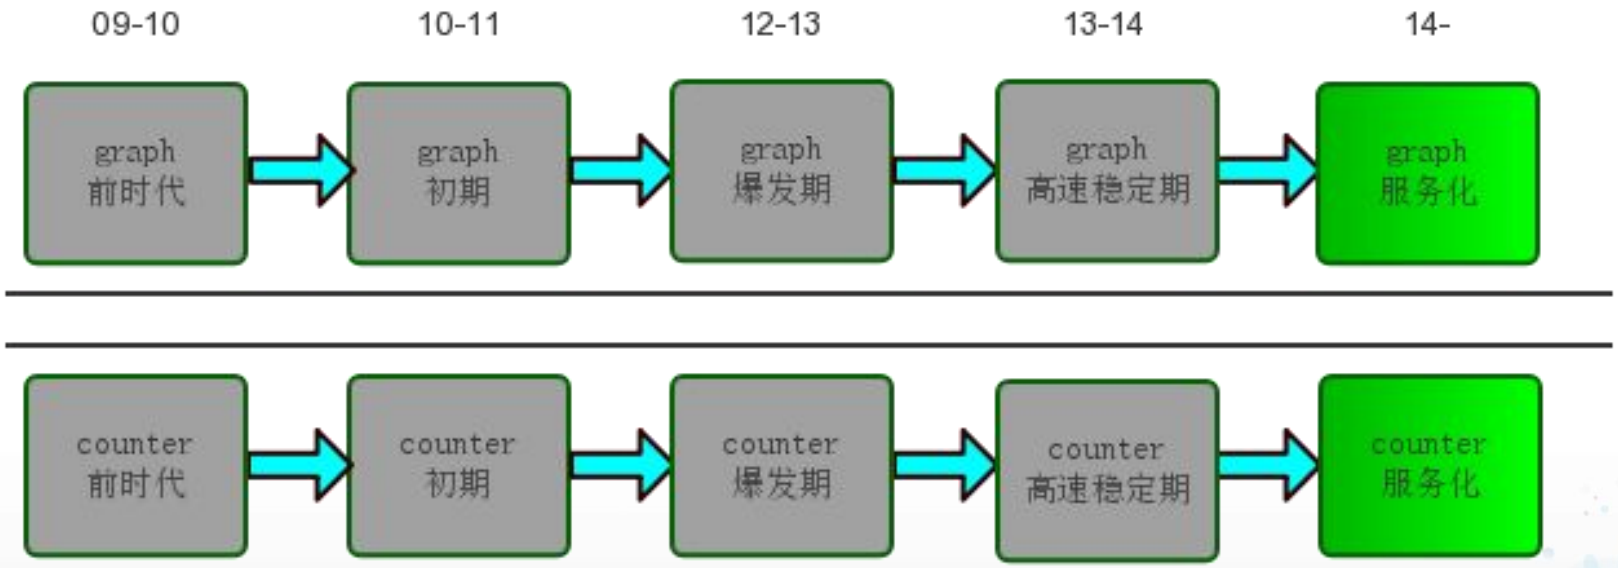
09-10
10-11
12-13
13-14
14-
graph 前时代
graph 初期
graph 爆发期
graph 高速稳定期
graph 服务化
counter 前时代
counter 初期
counter 爆发期
counter 高速稳定期
counter 服务化

服务化

- 服务化 →
  - 业务服务化 motan ✓
  - 资源服务化 →

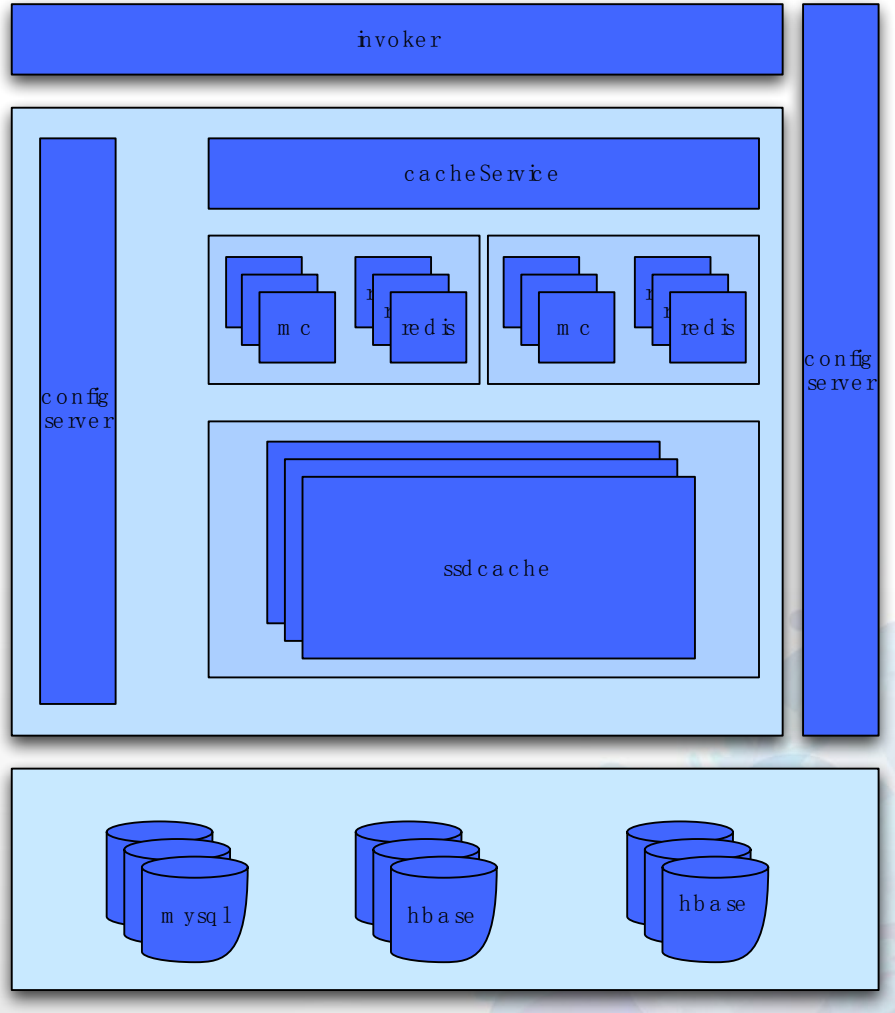

小结

- 避免过早优化，小步快跑
- 架构没有最好，只有更适合

一些经验

- 结合发展阶段选择最合适的技术和架构，避免过早优化
- 拥抱需求，需求、技术相互促进
- 解决问题的root cause

Q&A

THANKS

SequeMedia 盛拓传媒 | IT168 www.it168.com | ChinaUnix | ITPUB